


Muhammed Essam

September 1, 2018

# Road to Deep Learning



By : Muhammed Essam

# Chapter 1

## Basics

- Intro to Neural Networks
- Biological Neural Networks
- ANN
- MLP
- Activation functions
- Optimization
- Gradient Descent
- First Model with Keras

# Intro to Neural Networks

لو انت **Developer** فأكيد زهقت من bugs في Code بتاعك من ان في مشاكل كتيرة أوي بتقابلك عشان تطلع حاجة تناسب Client وممكن تدخل نفسك في لسته من conditions لمجرد بس انك خايف من أي Action هوا ياخده وتبقي انت مش متوقعه .. وده ببدا يوصلنا لسؤال مهم .. هو مفيش طريق غير ده ؟ مينفعش أوصل لأسلوب أخلي الكود بتاعي يفكر ؟ وياخد قرار ؟؟

- عمرك سألت نفسك , انت ازاي بتفهم أي معلومة ؟ أو إزاي دماغك بتشتغل ؟


- تفتكر لو خيّرتك انك تبدل دماغك بكومبيوتر هتقبل ؟

- طيب تفتكر مين أفضل Computer ولا human brain ؟

- تفتكر ازاي المعلومات في دماغك مش بتخش في بعضها؟

## Biological Neural Networks


لان احنا محتاجين نعمل نظام مشابه لطريقة تفكير الانسان فاحنا كان لازم ندرس ازاى المخ البشري بيتعامل مع المعلومات .



تعالى نحاول نفهم الدنيا بطريقة بسيطة فى الحقيقة المخ بيتكون من خلايا عصبية بنسميها **Neuron** وهى فى الحقيقة بتستقبل المعلومة من الحواس بتاعتنا زى العين أو الأذن ...

الخلايا العصبية دي بتبقي مترتبة و متوصلة ببعض باشكال مختلفة وبتكون شبكة بنسميها الشبكة العصبية.

في الشكل اللي تحت ده هتلاقي فيه رسمة Neuron من جوا وهي متوصلة ب Neuron تانية .



أهم النقط في الشكل ده بالنسبة لنا هي ان قدامك راس الخلية وهو اللون الأصفر الكبير ده وبنسميه Soma وليه ديل أو طرف وهو اسمه Axon ... محتاجين ناخد بالنا من ايه بقي ؟ ان احنا بيبقي عندنا وليكن information في neuron وعايزة تبدأ تنقلها ف axon بينتهي ب Axon terminals أو بنسميها Synapses وبتستقبلها أطراف ال neuron التانية عن طريق dendrites وتوصلها لجوة Soma عند Nucleus نفسها وهكذا تبدأ هي كمان توصل اللي وراها بنفس الطريقة ..

طيب ايه النقطة المهمة بالنسبة لنا ؟ ان في الحقيقة كل neuron متوصلة بالاف من neurons فانت لو فكرت هتقول ان في فوضي ممكن تحصل والمعلومات تخش في بعض ... بس في الحقيقة يحصل نقطة مبهرة جدا وهي ان كل neuron يتحكم في جيرانها اللي متوصلة بيهم ياما تعملهم **firing** يعني تشغلهم أو لا ! فبالتالي neurons اللي شايلة المعلومة المطلوبة بس هي اللي بتوصل..

نوضح كلامنا مرة ثانية كل اللي قولناه :-


- المخ بيتكون من شوية **Neurons** متوصلة ببعض بتنقل المعلومات .
- كل **Neuron** بتبقي متوصلة بالاف من neurons وتعمل activation / firing لل neurons اللي بتأثر معاها في المعلومة
- المعلومات دي بتتمثل في الاخر ب **image** أو **memory** معينة أو... الخ

المفروض دلوقتي ان انت بدأت تربط انا احنا هحاول نقلد الفكرة دي بشكل اصطناعي **Artificial** ونشوف هنقدر نوصل منها لايه !




# Welcome to Artificial Neural Networks


من هنا هنبداً ندخل مجالنا وهو Computer Science فاحنا دلوقتي في خطوة ان احنا نقلد فكرة عمل neurons بتاعت المخ تمام؟



الكرات الزرقا والحمرا دي بالنسبة لنا هي **Neurons** أو ممكن تسميها **Nodes** طيب احنا برده هنا عايزين نوصل Neurons ببعض زي ما اتكلمنا في human brain عن Dendrites , Synapses هنا احنا هنوصل Neurons ببعض بحيث ان (( كل Neuron ليها input وهو output اللي قبلها وليها output وهو input اللي بعدها))! .... \* بص تحت علي الرسمة و اقراها مرة ثانية\*



تمام زي ماقلنا في human brain ان neuron متوصلة بعدد كبير جدا من neurons فاحنا برده هنا هنعوصل كل neuron باكثر من neuron .. بالمنظرده



دې في الحقيقة شكل Basic لل ANN = Artificial Neural Network ملاحظ ايه ؟

- في 3 حاجات رئيسية وهي Input layer , Output layer , hidden layer
- كل layer متكونة من عدد من Neurons



- كل Neuron متوصلة ب كل Neurons اللي وراها واللي قبلها ... وده اللي بنسميه **Fully Connected Neural Network** .
- في neuron واحدة في output layer يعني Single output طبعا ممكن يكون عندك Multiple outputs علي حسب Task

في سؤال مهم ؟ ازاى neural network بتتعلم ؟  
طب هرد عليك بسؤال أهم وهو ازاى انت نفسك إتعلمت ؟؟

. في الحقيقة انت في فترة كبيرة من حياتك مشيت فيها بمبدأ Supervised Learning يعني بتشوف حاجة قدامك حد بيعملها



وانت بتقلده لحد ما تقدر تعملها




في أمثلة كثيرة أوي لكدة لو فاكّر مثلاً انت ازاي اتعلمت تميز ما بين الحيوانات كنت مثلاً بتشوف صور ليها و يقعدوا قلوبك دي قطعة دي قطعة مثلاً ده كلب وبعد كده يبدأوا يسألوك ده ايه ؟ فانت تقول قطعة فيقولك صح .. فانت عرفت منين ؟ او اتعلمت منين ؟ من تجارب سابقة ليك!

طيب وصلت لايه من الكلام ده ؟

لان احنا بنحاول نقلد طريقة تعليمنا احنا كبشر فاحنا هنبدأ نستخدم أسلوب مشابه في Neural Networks !

فاحنا هنبداً نوخر شوية Data ولو تخيلنا ان احنا معنا Neural Network model ده وأكنه Black Box يعني حاجة انا مش عارف شغالة ازاي ... انا بس بوفرلها Data عبارة عن شوية Inputs وال Outputs بتاعتها بالمنظر ده




فانت دلوقتي معاك Model بيبدأ يعملك Classification يعني بتدخله صورة ويقولك هل ده قطعة ولا كلب ! ال Model بالنسبة لنا Black box يعني انت بتتعامل معاه دلوقتي انك بتديله inputs , outputs ..... وهو هيبداً عن طريق Data دي يقدر يتعلم ولو سألته علي حاجة بعد كده هل هي قطعة أو كلب يقدر يقولك توقعه أو تصنيفه ..

يبقي نقدر نقول ان Neural Network شرط انها تتعلم انك توفر لها Labeled Data يعني data ليها output سليم بنسميه Label .

بس في الحقيقة عشان Neural Network تتعلم بتحتاج تمشي علي مرحلتين أول حاجة هي Forward Propagation وتاني حاجة هي Backward Propagation .. بس قبل مانوضح معناهم ايه وبيتموا ازاى تعالوا نبدأ ب أساسيات Neural Network !

زي ما ال basic structure بتاع اي جسم عندك هو ال ذرة عندنا هنا في Neural Network ابسط وحدة هي **Perceptron**



ده شكل Perceptron بيبقي  
ليه أكثر من input اللي هما  
 $x_1$  ,  $x_2$  ,  $x_3$


فال Perceptron بتقوم بعملية جمع ليهم وتطلعك Output  
بس في Trick ان دلوقتي ده لو System عندك تفتكر هل  
كل Inputs بتأثر في Output بنفس القيمة ؟ أكيد لا

كل واحد ليه أهميته .. مثال يعني لو بنميز ما بين راجل وست  
هل لون البشرة بيأثر زي مثلا طول الشعر ؟ أكيد لا كل حاجة

ليها عندك أهمية بنسبها احنا هنا **Weight** وعشان كده بنبدأ نضرب كل Input اللي هي  $x$  عندنا في أهميته أو **Weight** يعني اللي هنسميه  $W$

طيب يبقى كده وصلنا ان  $y = w_1 * x_1 + w_2 * x_2 + w_3 * x_3$

فاضل خطوة بسيطة جدا وهي ان احنا بنعمل Adding لل **Bias** وهو بالنسبة لنا **Free term** يعني هو مش بيبقي ليه **variable input** ولا حتي **Connected** بال **Previous Layer**




فهو بتديك قدرة علي انك تتحكم في Output من غير أي اعتماد علي previous input وده حاجة مميزة جدا ..

بس لو حابب تفتكر انت شوفت **Bias** دي فين قبل كده فانت لو خدت مثال لأبسط شكل **Neural Network** هيبقي عبارة

عن **input 1** و **output 1** فهيبقي  $y = w_1 x$  لما تمثّلها graphically هتلاقىها عبارة عن خط مستقيم **Linear function**

انك تتحكم في  $w_1$  هتديك فرصة انك تتحكم في ميل الخط

يعني في الزاوية يعتبر .... طيب لو عايز اعمل Shift اصلا لل  
 Graph كله ؟ كنا ساعتها بنضيف Bias term عشان المعادلة  
 تبقى  $Y = mx + b$  اللي هي هنا  $y = w_1 x + b$




يبقي كده وصلنا ان احنا يعتبر في كل شغلنا بنضيف Node  
 زيادة وهي مش متوصلة بال previous layer وبيبقى ليها  
 weight بنسميه bias وبيبقى ليها input و قيمته 1

يبقي المعادلة النهائية اللي بتمثل **Perceptron**

$$Y = w_1 x_1 + w_2 x_2 + w_3 x_3 + 1 * b \text{ ( for Perceptron )}$$

تفكر احنا بيبقي عندنا perceptron واحدة ؟ لا غالبا بيبقي عندك اكثر من perceptron في Layer الواحدة وكلهم بيبقوا متوصلين ب inputs بتاعتك وبنأخذ output بتاع كل واحدة ونغذي بيها ال Layer اللي بعدها واكنه input بتاعهم وهكذا



Input layer (1) , Hidden Layers (2:5) , Output Layer(6)

الشكل اللي قدامك ده بيمثل **MLP** اللي هي Multi Layer Perceptron.... دلوقتي المفروض بيدأ يجيك سؤال ؟ هو ان في عدد كبير جدا من weights و biases موجود ... طيب هو مين اللي بيحسب قيمها ؟ لان اكيد كل ما هتغير فيهم كل ما هيتغير Outputs

في الحقيقة مش انت اللي بتحسب قيمهم .. انت بس بتعمل Random initialization ليهم يعني بتفرض أرقام عشوائية



ليهم كلهم و عن طريق Gradient Descent اللي موجود في Back Propagation بيبدأ يتعدّلوا للرقم الأقرب للصح ..

لحد دلوقتي احنا مشرحناش ايه هي Back ولا حتي Forward propagation بس بما اننا بنعمل explode لأشهر أساسيات Neural Networks فاحنا لازم نعرف دلوقتي يعني ايه gradient Descent و ايه أنواعه وده اللي احنا هنعرفه بشكل أوسع في . Optimization

# Optimization

في علم Data Analysis بشكل عام دائما يبقي عندنا Error وال Error ده بنمثله ب equation وبنسميها Cost function


فكلمة Optimization المقصود منها انك تعمل reduction لل Cost Function دي او ساعات بنسميها Losses بس تعالوا نفهم ازاى بنقل Error ده لو قلنا ان انت دلوقتي مثلا معاك Output معين Predicted وليكن قيمته 60 والمفروض الناتج الصح الحقيقي Actual يعني هو 100

يبقي بالنسبة لك Error لو خدنا احد أشكاله وهو انك تطرح بس ال 2 من بعض فكدّه

$$\text{Error} = \text{Predicted} - \text{Actual}$$


فلو حاولنا نحسب ال error هيطلع معنا 60-100 يعني 40

فتخيل معايا  
دلوقتي error  
ده قيمته  
اتقاطعت مع ال  
graph في  
نقطة عند  
initial weight  
معين .




فانت هدفك تخلي النقطة دي تحت عند أقل error اللي هو بنسميه Global Minimum ...  
بس هو ايه اللي هيوصلنا لتحت ايه اللي يعرفنا ؟

في الحقيقة Gradient descent هو بالنسبة لك عبارة عن Vector بيوجهك لأقل Error يعني لو بتكلم عن concave function زي دي من الدرجة الثانية فهو لما ناخذ derivative بتاعها هيبقي مجرد vector بيشارو لتحت فانت هتبدأ تنزل ب Rate معين بنسميه Learning Rate أو Alpha



بس Learning rate ليه قصة لازم نفهمها  
احنا في بعض Costfunctions هنتكلم عن انها مش مجرد Curve لا دي هي مثلا 3d بالشكل ده



فلو قلت ان ال Step بتاعتك هي Learning rate  
تخيل لو رقم صغير فانت هتقدر توصل minimum .. بس في  
الحقيقة ممكن تقع في Local minimum << اما لو كبيرة  
فهي ممكن تخليك تعمل jump من local لل global  
minimum وهو ده المطلوب لانه أقل Error

+ لو هي رقم صغير أوي فممكن متلحقش تتعلم يعني فترة  
التدريب تنتهي وانت لسه موصلتش لتحت ... اما لو رقم كبير  
فممكن متعرفش تقف بالضبط عند أقل نقطة ...

فالموضوع ليه حلول كتير ومشاكل أكثر هنوضحها فيما بعد  
بس تفكر هل انك تبدأ ب learning rate كبير وتصغر بعد كده  
ممكن يعالج المشكلة ؟؟

## Activation function


فاضل جزء بسيط اوي هنتكلم عنه وهو لو فاكرين في مخ الإنسان قلنا ان كل Neuron بيبقي متوصل بالاف من Neurons جيرانه يعني ويقدر يتحكم في firing بتاعهم .. فده بيديلك فرصة علي التحكم في مين من Neurons يوصل المعلومة ومين لأ ....

بالنسبة لنا احنا هو مفهوم مشابه لل Filters

## Step Function

احنا لما فكرنا كده قلنا نعمله زي فكرة Threshold بمعنى لو مثلا عندك درجات اكثر من طالب .. ففي طلاب جاييين 40% وفي طلاب جاييين 70% وهكذا .. فانت عايز تعمل ايه ؟ تحط درجة نجاح Threshold يعني اللي يبقى اعلي منها يبقى ناجح يعني 1 واللي أقل منها يبقى ساقط يعني 0 يعني في بعض القيم لما تدخل عندك في Activation function هتطلع ب 0 والباقي ب 1

مثال تاني يعني زي الرسمة اللي تحت ان لو  $X$  input أكبر من الصفر هيطلع الناتج 1 ولو ال  $X$  input اقل من 0 هيطلع الناتج 0 بص كويس علي  $X$  axis وعلي  $Y$  value




تمام أوي كده انا قدرت اعمل filter وممكن ييقي مثلا علي output layer ويعمل classification ما بين حاجتين .. بس عيب

حقيقي لل Step Function هي اني مش بقدر أعمل أكثر من Binary Classification يعني Male / Female , Dog/Cat لكن لو عندي أكثر من 2 زي مثلا خمسة Classes ساعتها هيفشل فبدأوا يفكروا في حل تاني زي Linear Function

# Linear function

لان احنا كنا محتاجين Analog output يعني بيختلف معايا فده هيو فرلي احتمالات من  $-\infty$  لحد  $+\infty$

فانت تقدر تقول ان هنا كل قيمة لل  $x$  ليها Class مختلف في  $y$



مثال لو قلنا ان احنا عندنا Classes ليها قيم  
Egypt = 0.65 , France 0.9, Germany 0.1

فلو طلع عندك ال input 0.5 ولو افترضنا ان ميل الخط 45 درجة  
هنقول كده output 0.5 برده يبقى لو قربنا الرقم لأي Class  
هيطلع عندي الناتج Egypt

بس ايه العيب ؟




العيب الحقيقي ظهر لما كنا نتكلم عن Gradient Descent ..  
فهو في الحقيقة هي عبارة عن Derivative لل Activation  
Function فطبعا لو عملت اشتقاق للخط المستقيم الناتج  
هيبي ايه ؟ Constant << وبالتالي مفيش حاجة هتعرفني  
اتجاه اقل error فين ...

فبدأنا نفكر في نوع ثاني يحل كل المشاكل اللي فاتت دي وهو

## Sigmoid function

فهو دي بالنسبة لنا الحل نشوف شكلها كده




بتوفر لنا موضوع threshold في انها بتنتهي ب 0 و 1 يعني ممكن اعمل filter .. كمان بتوفرلي Variance range هتلاقية مايل شوية وده بالنسبة لي Analog يعني كده تمام اقدر اعمل اكثر من Classification ... واخيرا بقي هي non linear فحتي لو عملت ليها derivative هتبقى vector وهو ده اللي انا عايزه ..

بس هي برده محكومة ب Range ان اخرها 0 ل 1 طيب افرض انا عايز حاجة بالسالب ؟

فظهر نوع ثاني وهو

## Tanh function


وهي هتوفر لنا Range أوسع من Sigmoid بس ميل هيتلف شوية .. ليها تطبيقات كتير بس مش هنحتاج نخش في تفاصيلها دلوقتي



# Relu Function

وهي اخر نوع جابيين نتكلم عنه دلوقتي بياخد ميزة Range ال Linear function وفي نفس الوقت ميزة Filter ودمجهم مع بعض ب Range from Zero to - inf

بالشكل ده طبعا لو فكرت تاخذ اشتقاق الخط الثابت اللي عند zero ده فانت بتعمل اشتقاق ل Constant وطبعا الناتج هيبقى صفر ...



ودي بتوجهنا لمشكلة بنسميها Dying Relu ... هنتكلم عنها فيما بعد بشكل اوضح بس Relu function من أشهر Activation functions المستخدمة

دلوقتي احنا بقينا جاهزين نفهم ايه Process اللي بتحصل عشان Neural Network تتعلم وتوصل ل Solution

وده بيحصل علي مرحلتين

- \* Forward Propagation
- \* Backward Propagation

## Forward Propagation

وهي بالنسبة لنا كل الخطوات اللي بتتم من أول ما بنعمل Random initialization لكل Wiegths لحد مانوصل لل Output مروراً بكل Perceptrons بتاعتنا وال Activation functions والقصة دي كلها

بمعني ان :-

هدف Forward Propagation هو الوصول ل Output بعد سلسلة من العمليات ..

بس هل Output ده صح ؟ يعني هيساوي Actual ؟  
أكيد لأ لانه مبني علي Random weights .....

## Backward Propagation

وهي الهدف منها انك تعمل update لل Weights اللي عندك من الآخر للأول يعني بهدف تقليل ال Error وده هيتم أكيد وسط Algorithms من Gradient Descent و parameters Learning Rate تانية زي

هل بعد ما عملنا Backward propagation كده احنا خلاص يعني جاهزين لو عملنا Forward مرة ثانية ان احنا نوصل للهدف بالضبط ؟

أكيد لأ برده انت بس ممكن تبقي قللت ال error فمحتاج تكرر الموضوع ده مرة و اتنين وتلاتة وهكذا

اللفة المكونة من Forward Propagation + Backward Propagation احنا بنسميها **Epoch**

كل ما بتزود عدد Epochs بيفرق كثير معاك في الوقت والجهد علي Processor ده غير انك برده ممكن تتجه ناحية مشكلة كبيرة أوي وهي **Over fitting**.

لحد هنا ممكن نقول احنا نكتفي بالمعلومات دي بشكل مبدئي في علم Neural Networks وممكن نبدأ نتجه ناحية Coding شوية ونشوف هنقدر نوصل لايه باذن الله

# Develop Your First Model With Keras

باذن الله هنشغل Python Programming Language وده نظرا  
لأسباب كثيرة جدا منها سهولتها و كثرة Libraries بتاعتها  
وانها حصلت علي لقب لغة Deep Learning وده طبعا نظرا  
لانها Open Source



و طبعا لكثرة المكتبات  
وصعوبة تنزيل بعضها فاحنا  
هنتجه باذن الله ل Platform

اسمها Anaconda



هتوفرلنا IDE زي Jupyter  
وكمان هتدينا tool ل Library  
installation وهي Conda  
وكمان هتساعدنا نبني أكثر

**ANACONDA**

من Environment بشكل بسيط جدا

## Some Installation Tips:-

أول خطوة هي انك تنزل Anaconda سواء انت Linux أو Windows أو Mac

<https://www.anaconda.com/download/>

بعد ما تختلص installation لو انت Windows هتتابع معنا من Anaconda Prompt  
أما لو Linux هتتابع معنا من Terminal عادي

لو عايز تتأكد ان كل حاجة نزلت صح أكتب Python في Terminal/Anaconda Prompt

لو ظهر لك

python3.6/ Anaconda-Custom ... etc

اعرف ان انت كده تمام وجاهز انك تبدأ



## هنشتغل باذن الله من Jupyter lab

```
meracoda@meracoda-Lenovo-G510: ~  
bash: /opt/ros/lunar/setup.bash: No such file or directory  
meracoda@meracoda-Lenovo-G510:~$ jupyter lab  
[I 13:31:43.616 LabApp] Writing notebook server cookie secret to /run/user/1000/jupyter/notebook_cookie_secret
```

هتختار python3 من Notebook وكده انت جاهز رسميا نبدأ  
سوا أول برنامج لينا

# Your first Neural Network with Keras (Diabetes Classifier)

-Most of Code are taken from [here-](#)

هنبداً دلوقتى نحاول نعمل كود بيصنف هل العينة اللي قدامه  
دي مصابة بمرض السكري ولا لا

ايه الخطوات اللي هنمشي عليها ؟

- 1- Load Data
- 2- Data preprocessing
- 3- Build the Model
- 4- Training
- 5- Prediction

الكود ده مجرد عرض لشكل Neural Network مش الهدف منه  
انك تتعلم Coding وتبقي جاهز هو مجرد عرض فقط وتاخذ  
فكرة بسيطة عن شكل الكود و Parameters بتاعته

## 1- Load Data

طبعا عشان تعمل Load لل Data الموضوع بيبقي متوقف علي العميل بتاعك موفرلك Data صيغتها ايه احنا في حالتنا دي متوفرلنا csv file

وهو diabetes.csv .. حمل Data من هنا < [Dataset](#)

أبسط طريقة انك تقرا File ده هي انك تستخدم function اسمها read\_csv بس هي مش متوفرة في Python فहतضطر تناديها من library اسمها pandas بالشكل ده

```
import pandas as pd
df = pd.read_csv('diabetes.csv')
df
```

تعالوا نشوف الناتج عامل ازاي ... في الحقيقة قدامنا Table محترم متقسم ل 9 عواميد بالشكل ده .. بس في مشكلة ان Data نفسها جايالنا من غير header فاحنا هنضطر نجيب headers نفسها عشان الدنيا تترتب شوية

The screenshot shows a JupyterLab window with a file named 'Kerasmodel.ipynb'. The output of a cell, labeled 'Out[2]:', displays a table of data. The table has 12 columns and 12 rows. The first row is a header, and the subsequent rows are data points. The columns represent various features and a target variable.

	6	148	72	35	0	33.6	0.627	50	1
0	1	85	66	29	0	26.6	0.351	31	0.0
1	8	183	64	0	0	23.3	0.672	32	1.0
2	1	89	66	23	94	28.1	0.167	21	0.0
3	0	137	40	35	168	43.1	2.288	33	1.0
4	5	116	74	0	0	25.6	0.201	30	0.0
5	3	78	50	32	88	31.0	0.248	26	1.0
6	10	115	0	0	0	35.3	0.134	29	0.0
7	2	197	70	45	543	30.5	0.158	53	1.0
8	8	125	96	0	0	0.0	0.232	54	1.0
9	4	110	92	0	0	37.6	0.191	30	0.0
10	10	168	74	0	0	38.0	0.537	34	1.0
11	10	139	80	0	0	27.1	1.441	57	0.0

وده عن طريق Data Set Details من اللينك ده

## Data set Details

فهنعدل في read csv function وهنخليها بالمنظر ده

```
df = pd.read_csv('diabetes.csv', sep=',',
                 names = ["Number of times
pregnant", "Plasma", "blood pressure",
"Triceps skin fold thickness",'insulin','Body
mass','Diabetes pedigree
function','Age','Class variable'])
df
```

Out[3]:

	Number of times pregnant	Plasma	blood pressure	Triceps skin fold thickness	insulin	Body mass	Diabetes pedigree function	Age	Class variable
0	6	148	72	35	0	33.6	0.627	50	1.0
1	1	85	66	29	0	26.6	0.351	31	0.0
2	8	183	64	0	0	23.3	0.672	32	1.0
3	1	89	66	23	94	28.1	0.167	21	0.0
4	0	137	40	35	168	43.1	2.288	33	1.0
5	5	116	74	0	0	25.6	0.201	30	0.0
6	3	78	50	32	88	31.0	0.248	26	1.0
7	10	115	0	0	0	35.3	0.134	29	0.0
8	2	197	70	45	543	30.5	0.158	53	1.0
9	8	125	96	0	0	0.0	0.232	54	1.0
10	4	110	92	0	0	37.6	0.191	30	0.0

## 2-Data PreProcessing

لحدهنا احنا خلصنا خطوة Loading Data وكمان يعتبر بدأنا في Pre Processing بخطوة تعديل ال Header

الخطوة اللي جاية دلوقتي ان احنا هحاول نقسم جزء Features لوحده وهو X وجزء Y لوحده وهو Label

في function عندنا اسمها iloc هتحتاج منك object اللي هو table /Matrix يعني عشان تبدأ تتحرك فيها وتاخذ جزء من Matrix وتفصله لوحده لو عايز

فانت دلوقتي عايز تاخذ علي سبيل المثال X  
هي أول 8 أعمدة و مثلا اول 760 صف  
فهدخله

From 0 : 760 in rows and 0: 8 in columns

اما Y فهدخل

From 0:760 in rows and the 8th column

```
x=df.iloc[0:760,0:8]  
y=df.iloc[0:760,8]
```

تقدر تعمل Check بانك تشوف قيمة X او y ايه هي !

### 3-Build the Model

فهو في الحقيقة احنا نفترض عايزين نعمل Model مكون من

Input Layer - 8 Input Neurons

First hidden Layer -12 Neurons ( Fully connected / Dense)  
with relu

Second hidden layer - 8 Neurons (Fully connected/Dense)  
with relu

## Output layer - 1 Neuron ( to tell if its 0 / 1 ) with Sigmoid

في الحقيقة احنا هنستخدم Keras وهو بيتبع أسلوب بنسبيه Sequential Model نقدر نقول ان احنا بنعمل Sequential Model ونبدأ بعديه نضيف Layer ورا الثانية

```
model = Sequential()
model.add(Dense(12, input_dim=8,
init='uniform', activation='relu'))
model.add(Dense(8, init='uniform',
activation='relu'))
model.add(Dense(1, init='uniform',
activation='sigmoid'))
```

فاحنا ده بالظبط اللي قلنا فوق ماعدا كلمة uniform ممكن نعيدها دلوقتي ونرجعها في Week 2

لكن بالفعل احنا عملنا أول Layer مكونة من 12 نيورون وهي منتظرة من input كام ؟ منتظرة 8 ونوع Activation هو relu وهكذا باقي السطور وطبعاً زي ما قلنا بنعمل Sequential model ونبدأ نضيف Layer ورا الثانية ...



### 3- Train the Model

دلوقتي هنتنقل لخطوة Training احنا مش interested دلوقتي في كل تفاصيلها اكر من اني بجهر فيها Optimizer بتاعي سواء gradient descent أو غيره وكمان بدخله cost function بتاعتي سواء هي طريقة حساب error العادية او شكل تاني زي binary cross entropy وهنتكلم عنها فيما بعد

وبدخل فيها موضوع Epoch واشوف عايز كام لفة و اعرف ال model شكل X,Y اللي هو features , labels بتاعتي

```
model.compile(loss='binary_crossentropy',  
optimizer='adam', metrics=['accuracy'])  
  
model.fit(x, y, epochs=200, batch_size=32,  
verbose=2)
```

وهيبدأ بالفعل يعمل Training بالشكل اللي تحت ده

```
Epoch 74/200  
- 0s - loss: 0.5363 - acc: 0.7368  
Epoch 75/200  
- 0s - loss: 0.5347 - acc: 0.7368  
Epoch 76/200  
- 0s - loss: 0.5309 - acc: 0.7368  
Epoch 77/200  
- 0s - loss: 0.5332 - acc: 0.7382  
Epoch 78/200  
- 0s - loss: 0.5272 - acc: 0.7342  
Epoch 79/200  
- 0s - loss: 0.5273 - acc: 0.7447  
Epoch 80/200  
- 0s - loss: 0.5250 - acc: 0.7395  
Epoch 81/200  
- 0s - loss: 0.5250 - acc: 0.7395  
Epoch 82/200  
- 0s - loss: 0.5224 - acc: 0.7461  
Epoch 83/200  
- 0s - loss: 0.5346 - acc: 0.7539  
Epoch 84/200
```

كده فاضلك خطوة اخيرة وهي انك لو حابب تعمل Prediction

## 4-Prediction

فانت دلوقتي ممكن تاخد أي سطر من Data وابدأ غير في أرقامه ودخلها له في array وشوف هيعمل prediction بكام طبعا لو اقرب لل 0 يبقى هي مريضة لو أقرب لل 1 يبقى هي سليمة

```

Xnew =
numpy.array([[2,82,50,20,0,10.4,0.2,1]])
# make a prediction
ynew = model.predict(Xnew)
# show the inputs and predicted outputs
print("X=%s, Predicted=%s" % (Xnew[0],
ynew[0]))

```

عدل في ال أرقام بتاعت array براحتك وشوف كل مرة  
 هيطلعلك prediction عامل ازاي  
 وتقدر تضيف function round للتقريب يعني

```

In [17]: Xnew = numpy.array([[2,82,50,20,0,10.4,0.2,1]])
# make a prediction
ynew = model.predict(Xnew)
# show the inputs and predicted outputs
print("X=%s, Predicted=%s" % (Xnew[0], ynew[0]))

X=[ 2. 82. 50. 20. 0. 10.4 0.2 1. ], Predicted=[0.02140561]

```

لو في أجزاء من الكود مش واضحة ده طبيعي الهدف النهائي  
كان أنك بس تشوف الكود بيبقي ماشي ازاي وايه علاقته  
باللي شرحناه بشكل عام ...

## هنتعلم في Week 2 أو Chapter 2 :-

- ايه هي Deep Neural Networks ؟
- هنتعلم Convolution Neural Networks !
- هنعمل CNN Code on MNIST Data set .
- هنتعلم Tensor Flow .
- و Concepts كتيرة جدا في CNN .
- و اخيرا هنعمل code hardware with Arduino .

**END OF WEEK 1**















